

PRML 5.1. Feed-forward Network Functions.

[1]

$$y(x, w) = f \left(\underbrace{\sum_{j=1}^M w_j \phi_j(x)}_{\text{線型和}} \right)$$

非線型活性化関数 非線型基底関数

NNとも同様
activation (≡ 活性化・ポテンシャル)

$$a_j = \sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)} \quad (x_1, \dots, x_D \rightarrow D\text{-次元入力})$$

非線型活性化関数 $j = 1, \dots, M \mapsto \lambda$ カレイヤ

$$z_j = h(a_j)$$


h : sigmoid, tanh, etc.
↳ DeepならReLUもよく使う

微分可能

$$a_k = \sum_{j=1}^M w_{kj}^{(2)} z_j + w_{k0}^{(2)}$$

$$y_k = \sigma(a_k)$$

$\sigma(a) = \frac{1}{1 + \exp(-a)}$
 σ : sigmoid (2値分類) — 微分可能
↳ 回帰なら恒等写像



← 3層ネットワーク

入力層も含む

◎ 2層ネットワーク
適応層の数.

◦ 単一隠れ層ネットワーク
の3つの呼び方がある。

(p. 299)

まとめると、

$$y_R(x, w) = \sigma \left(\sum_{j=1}^M w_{Rj}^{(2)} h \left(\sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)} \right) + w_{R0}^{(2)} \right)$$

→ 順伝播の式

また、 $x_0 = 1$ とすると、バイアス項 $w_{j0}^{(1)}$, $w_{R0}^{(2)}$ もまとめられ、

$$y_R(x, w) = \sigma \left(\sum_{j=1}^M w_{Rj}^{(2)} h \left(\sum_{i=0}^D w_{ji}^{(1)} x_i \right) \right)$$

[2] NNと10-ビットロンの違い

微分可能

NN $\rightarrow \sigma$ (sigmoid; continuous, differentiable)

↓

10-ビットロン \rightarrow (step; 微分不可!)

key hole in NN

もし、全ての隠し層の活性化関数が「線型」なら... (※)

↓

線型な関数(行列)の積としてまとめられ、隠し層がないのと同じ。

↓

※のような状況には関係がない。


もし隠し層の次元が入出力の次元より小さくなる...

↓


次元削減 = 一般的な「線型写像にならない」

→ 「主成分分析」を得る (意味はある)

[3] 層を飛び越えた結合.




Sigmoid を隠れ層に持つ.



(実際には左図とつづらぐとすゝめか...)

[4] サイクルがあると数学表現できつい (戻ると定気できつい)

↓
Feed-forward できついとダメ.



[5] NN = 万能近似器 (図 6.3)

[6] $x \rightarrow$ 隠

$$\tanh(-a) = -\tanh(a)$$

↓
for each weight (num = M)

隠 \rightarrow 出
 \rightarrow 対称 : M!

重み空間対称性

2^M の等価なバリエーション
 $M! 2^M$ の等価な重み
 \rightarrow どーでもいーい.